

# Detalles - QyA

Juan M. Scavuzzo

Facultad de Matemática, Astronomía, Física y Computación  
Universidad Nacional de Córdoba

Diciembre de 2018



# Variables Ambientales utilizadas para NED

- MODIS

- Valores medios mensuales de NDVI

- Wordclim

- BIO1 = Annual Mean Temperature
  - BIO2 = Mean Diurnal Range (Mean of monthly (max temp - min temp))
  - BIO3 = Isothermality (BIO2/BIO7) (\* 100)
  - BIO4 = Temperature Seasonality (standard deviation \*100)
  - BIO5 = Max Temperature of Warmest Month
  - BIO6 = Min Temperature of Coldest Month
  - BIO7 = Temperature Annual Range (BIO5-BIO6)
  - BIO8 = Mean Temperature of Wettest Quarter
  - BIO9 = Mean Temperature of Driest Quarter
  - BIO10 = Mean Temperature of Warmest Quarter
  - BIO11 = Mean Temperature of Coldest Quarter
  - BIO12 = Annual Precipitation
  - BIO13 = Precipitation of Wettest Month
  - BIO14 = Precipitation of Driest Month
  - BIO15 = Precipitation Seasonality (Coefficient of Variation)
  - BIO16 = Precipitation of Wettest Quarter
  - BIO17 = Precipitation of Driest Quarter
  - BIO18 = Precipitation of Warmest Quarter
  - BIO19 = Precipitation of Coldest Quarter

# Algoritmos utilizados

# Algoritmos utilizados: KNNR

- Utiliza los  $K$  puntos conocidos más cercanos para predecir el nuevo
- En regresión, el valor predicho suele ser el promedio del valor de los  $K$  vecinos más cercanos

# Algoritmos utilizados: DTR

- Método no-paramétrico de aprendizaje supervisado
- Usado tanto para regresión como clasificación
- Estructura Arbórea: nodos de decisión, nodos hojas
- Proceso iterativo de división de los datos

# Algoritmos utilizados: DTR

- Método no-paramétrico de aprendizaje supervisado
- Usado tanto para regresión como clasificación
- Estructura Arbórea: nodos de decisión, nodos hojas
- Proceso iterativo de división de los datos

Supongamos que los datos del nodo  $m$  son representados por  $Q$

- Para cada candidato se divide en  $Q_{izq}(\theta)$  y  $Q_{der}(\theta)$  donde
  - $\theta = (j, t_m)$ ,  $j$  es una característica y  $t_m$  es el umbral
  - $Q_{izq}(\theta) = (x, y) | x_j \leq t_m$   
 $Q_{der}(\theta) = Q - Q_{izq}(\theta)$

# Algoritmos utilizados: DTR

- Supongamos que hay  $N(m)$  observaciones
- En cada paso, se busca minimizar la función  $m$

$$G(Q, \theta) = \frac{n_{izq}}{N_m} H(Q_{izq}(\theta)) + \frac{n_{der}}{N_m} H(Q_{der}(\theta))$$

donde  $H()$  es la función de impureza de  $m$


- En regresiones, la función de impureza suele ser el MSE o el MAE
- Luego, se seleccionan los parámetros tal que

$$\theta^* = \operatorname{argmin}_{\theta} G(Q, \theta)$$



# Algoritmos utilizados: SVR

- Construye un hiperplano o un conjunto de hiperplanos en un espacio de muy alta dimensionalidad




# Algoritmos utilizados: SVR

- Busca aproximar la función desconocida  $F(\vec{X}) = \vec{Y}$
- Los  $\vec{X}$  son utilizados para definir los hiperplanos que separa las soluciones
- En el caso de regresión, se utilizan los hiperplanos para ajustar la curva
- Se tiene una tolerancia de  $\epsilon$  para cada punto

# Algoritmos utilizados: MLP

- Es un tipo de ANN *feedforward*
- Utiliza *backpropagation*
- Tiene, al menos tres capas: capa de entrada, capa oculta, capa de salida.



# Algoritmos utilizados: MLP

Para una MLP de una capa oculta con una sola neurona

- Dados datos de entrenamiento  $(x_1, y_1), \dots, (x_n, y_n)$  donde  $x_i \in \mathbb{R}^m$
- Aprende la función

$$f(x) = W_2 g(W_1^T x + b_1) + b_2$$

donde

- $W_1 \in \mathbb{R}^m$  y  $W_2, b_1, b_2 \in \mathbb{R}$  son parámetros del modelo
- $W_1, W_2$  representan los pesos de la capa de entrada y la capa oculta
- $b_1, b_2$  representan el sesgo agregado a la capa oculta y la capa de salida
- $g() : \mathbb{R} \rightarrow \mathbb{R}$  es la función de activación

# Algoritmos utilizados: MLP

- En problemas de regresión, la salida del algoritmo es  $f(x)$  por lo que  $g()$  es la identidad
- Utiliza como función de pérdida el *Error Cuadrático*

$$Loss(\hat{y}, y, W) = \frac{1}{2} \|\hat{y} - y\|_2^2 + \frac{\alpha}{2} \|W\|_2^2$$

- Luego

$$W^{i+1} = W^i - \epsilon \nabla Loss_W^i$$